




Data Science
Academy

Data Science Academy rodrigo.c.abreu@hotmail.com 5e207d48e32fc335fa60447d

Machine Learning



Data Science Academy rodrigo.c.abreu@hotmail.com 5e207d48e32fc335fa60447d




**Data Science
Academy**

Seja muito bem-vindo(a)!



Data Science Academy rodrigo.c.abreu@hotmail.com 5e207d48e32fc335fa60447d



**Data Science
Academy**

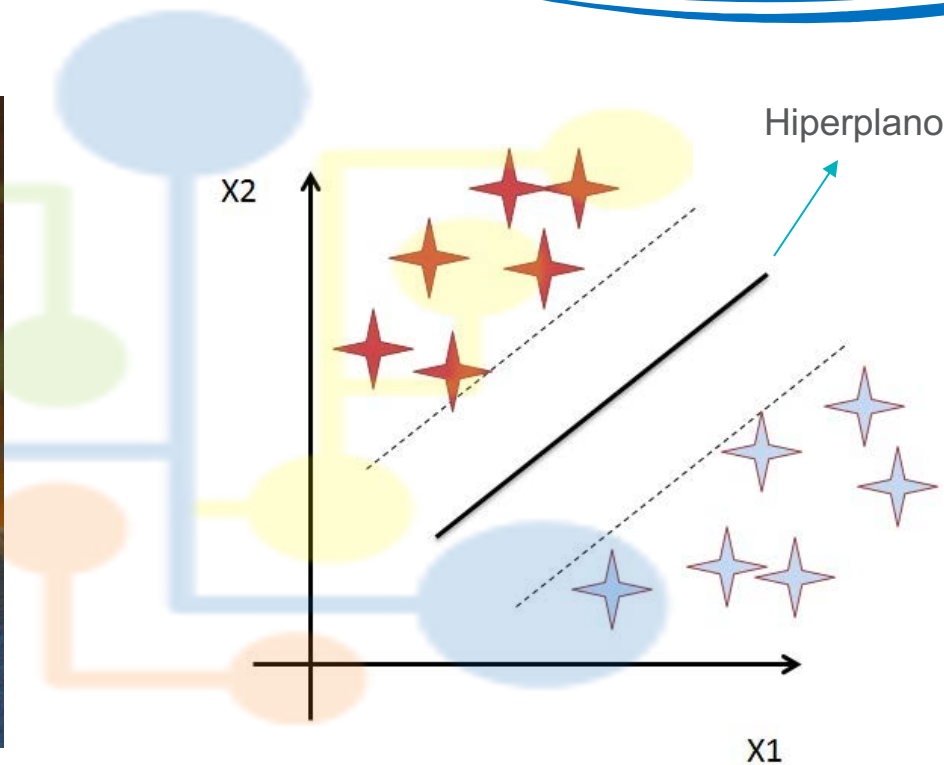
O Que São SVMs?




Regressão Linear



SVM







Algumas características das SVM's:

- Em caso de outliers o modelo SVM busca a melhor forma possível de classificação e, se necessário, desconsidera o outlier;
- É um classificador criado para fornecer separação linear;
- Funciona muito bem em domínios complicados, em que existe uma clara margem de separação;
- Não funciona bem em conjuntos de dados muito grandes, pois o tempo de treinamento é muito custoso;
- Não funciona bem em conjuntos de dados com grande quantidade de ruídos;
- Se as classes estiverem muito sobrepostas deve-se utilizar apenas evidências independentes.



Data Science
Academy

Data Science Academy rodrigo.c.abreu@hotmail.com 5e207d48e32fc335fa60447d

Machine Learning

```
mirror_mod.modifier_ob.  
mirror_mod.object to mirror.  
mirror_mod.mirror_object =  
operation == "MIRROR_X":  
mirror_mod.use_x = True  
mirror_mod.use_y = False  
mirror_mod.use_z = False  
operation == "MIRROR_Y":  
mirror_mod.use_x = False  
mirror_mod.use_y = True  
mirror_mod.use_z = False  
operation == "MIRROR_Z":  
mirror_mod.use_x = False  
mirror_mod.use_y = False  
mirror_mod.use_z = True
```


```
selection at the end -ad  
mirror_ob.select= 1  
mirror_ob.select=1  
context.scene.objects.active  
("Selected" + str(modifier_ob))  
mirror_ob.select = 0  
bpy.context.selected_obj  
data.objects[one.name].select  
print("please select exactly one object")
```

```
OPERATOR CLASSES  
types.Operator):  
X mirror to the selected  
select.mirror_mirror_x"  
mirror X"
```

```
context):  
object is not
```




Data Science Academy rodrigo.c.abreu@hotmail.com 5e207d48e32fc335fa60447d



**Data Science
Academy**

Funcionamento das SVMs



Support Vector Machines (SVM's) são modelos de aprendizagem supervisionada, que possuem algoritmos de aprendizagem que analisam dados e reconhecem padrões, utilizados para classificação e análise de regressão.






Funcionamento do Modelo SVM para dados linearmente separáveis.



Dados Não Linearmente
Separáveis

Dados Linearmente
Separáveis







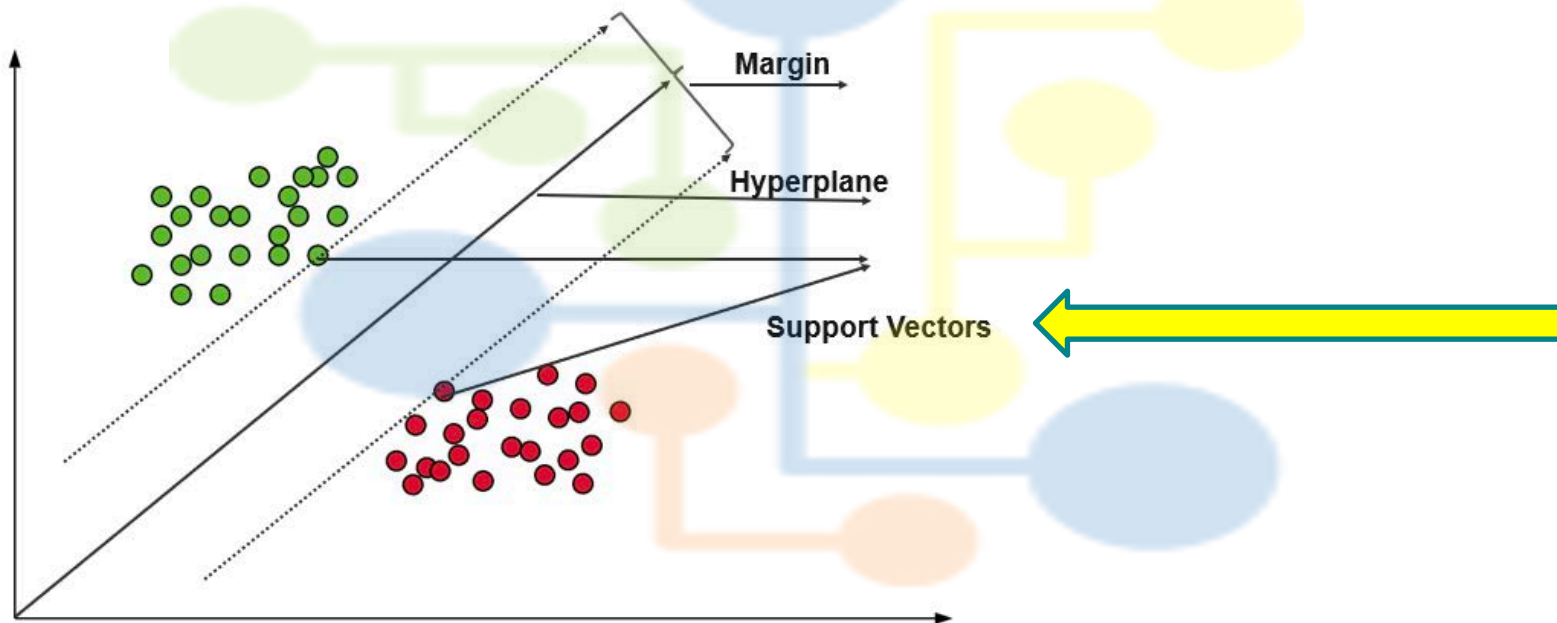
Dados Não Linearmente
Separáveis

Dados Linearmente
Separáveis

Precisamos de Função de
Kernel Para a Separação




Funcionamento do Modelo SVM para dados linearmente separáveis.





Uma Dose de Matemática



Encontrar o valor de y :


$$y^{(i)} = \begin{cases} -1 & \text{if } \mathbf{w}^T \mathbf{x}^{(i)} + b \leq -1 \\ 1 & \text{if } \mathbf{w}^T \mathbf{x}^{(i)} + b \geq 1 \end{cases}$$

Distância Mínima Entre os VS:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{\|\mathbf{w}\|}{2} + C \sum_{i=1}^N \xi^{(i)}, \\ \text{s. t.} \quad & y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \xi^{(i)}, \quad \forall i \in \{1, \dots, N\} \\ & \xi^{(i)} \geq 0, \quad \forall i \in \{1, \dots, N\} \end{aligned}$$



Uma Dose de Matemática



Distância Mínima Entre os VS:


$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{\|\mathbf{w}\|}{2} + C \sum_{i=1}^N \xi^{(i)}, \\ \text{s.t.} \quad & y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \xi^{(i)}, \quad \forall i \in \{1, \dots, N\} \\ & \xi^{(i)} \geq 0, \quad \forall i \in \{1, \dots, N\} \end{aligned}$$

Maximizar a Distância Mínima
(Otimização):

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha^{(i)} - \sum_{i=1}^N \sum_{j=1}^N \left(y^{(i)} \alpha^{(i)} \phi(\mathbf{x}^{(i)})^T \phi(\mathbf{x}^{(j)}) y^{(j)} \alpha^{(j)} \right) \\ \text{s.t.} \quad & 0 \leq \alpha^{(i)} \leq C, \end{aligned}$$



Uma Dose de Matemática



**Maximizar a Distância Mínima
(Otimização):**

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha^{(i)} - \sum_{i=1}^N \sum_{j=1}^N \left(y^{(i)} \alpha^{(i)} \phi(\mathbf{x}^{(i)})^T \phi(\mathbf{x}^{(j)}) y^{(j)} \alpha^{(j)} \right) \\ \text{s.t.} \quad & 0 \leq \alpha^{(i)} \leq C, \end{aligned}$$

Inner Product
O Kernel Trick é este
mapeamento.

Coeficiente aprendido
durante o treinamento, um
para i e outro para j.



Uma Dose de Matemática

O produto escalar entre dois vetores (dot product) mostra como os vetores são "semelhantes". Se os vetores representam pontos no seu conjunto de dados, o produto escalar informa se eles são semelhantes ou não.

Mas, em alguns (muitos) casos, o produto escalar não é a melhor métrica de similaridade.


Por exemplo:

Talvez os pontos com produto escalar baixo sejam semelhantes por outras razões. Você pode ter itens de dados que não estão bem representados como pontos ou pode não haver separação linear.

Então, em vez de usar o produto escalar, você usa um "kernel", que é apenas uma função que recebe dois pontos e fornece uma medida de sua similaridade. O SVM aplica esse conceito que é denominado Truque do Kernel (Kernel Trick).



Uma Dose de Matemática




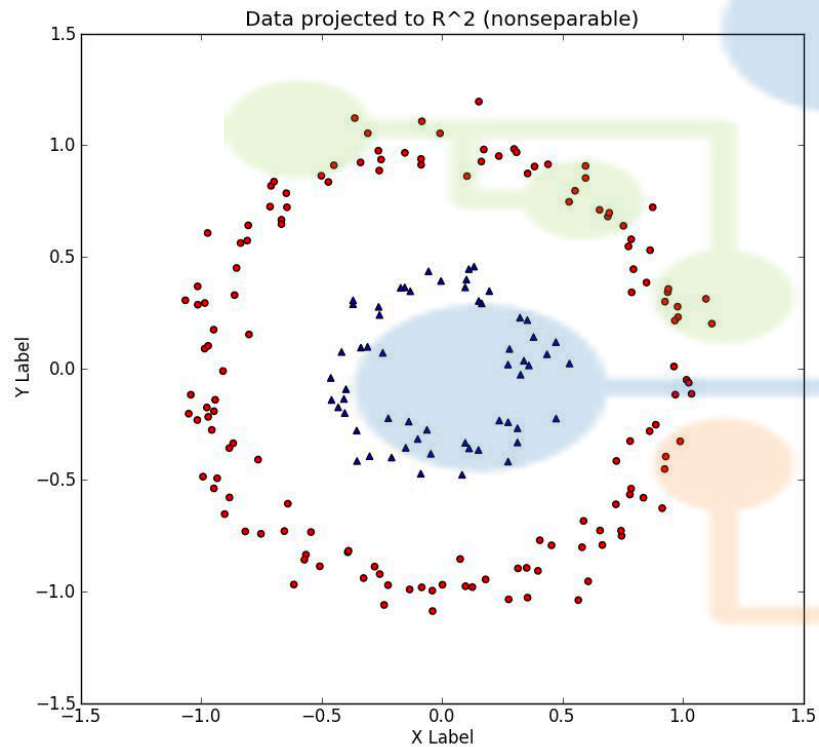
Previsões do Modelo:

$$y^{\text{test}} = \text{sign}(\mathbf{w}^T \phi(\mathbf{x}^{\text{test}}) + b)$$

$$= \text{sign}\left(\sum_{i=1}^N \alpha^{(i)} y^{(i)} \phi(x^{(i)})^T \phi(\mathbf{x}^{\text{test}}) + b\right)$$




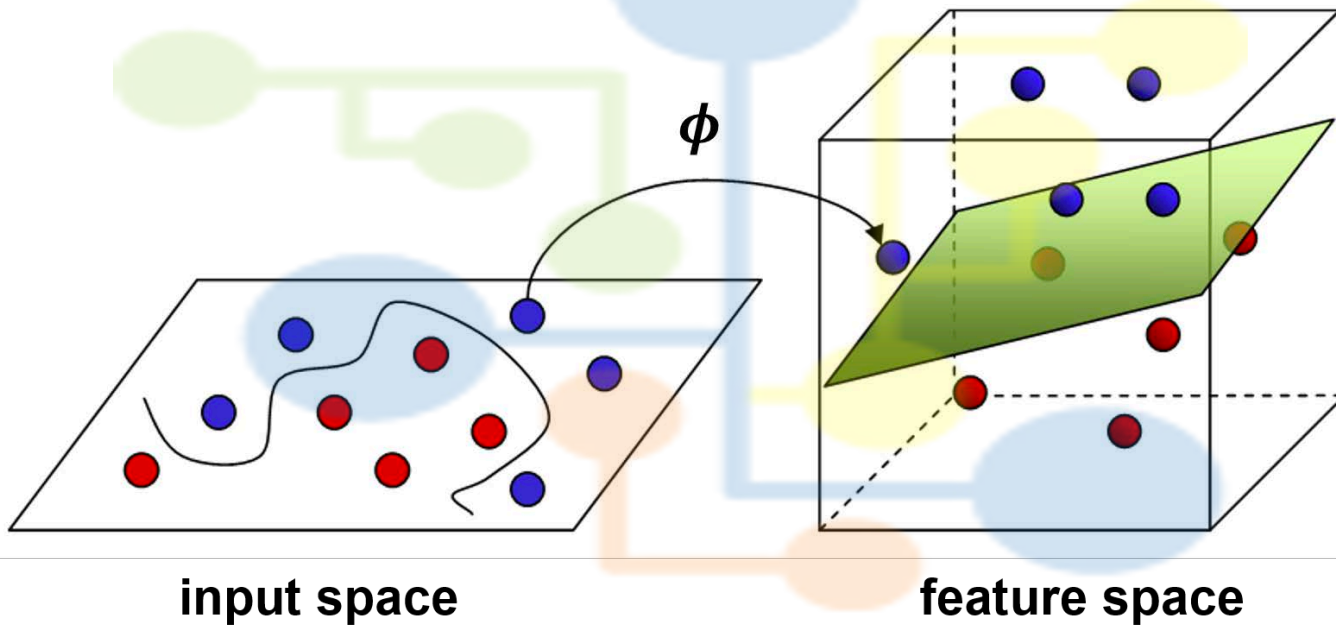
Funcionamento do Modelo SVM para dados NÃO linearmente separáveis.






Data in \mathbb{R}^3 (separable w/ hyperplane)








Data in R^3 (separable w/ hyperplane)



Data projected to R^2 (hyperplane projection shown)





Data Science
Academy

Data Science Academy rodrigo.c.abreu@hotmail.com 5e207d48e32fc335fa60447d

Machine Learning

```
mirror_mod.modifier_ob.  
mirror_mod.object to mirror.  
mirror_mod.mirror_object =  
operation == "MIRROR_X":  
mirror_mod.use_x = True  
mirror_mod.use_y = False  
mirror_mod.use_z = False  
operation == "MIRROR_Y":  
mirror_mod.use_x = False  
mirror_mod.use_y = True  
mirror_mod.use_z = False  
operation == "MIRROR_Z":  
mirror_mod.use_x = False  
mirror_mod.use_y = False  
mirror_mod.use_z = True
```


```
selection at the end -ad  
mirror_ob.select= 1  
mirror_ob.select=1  
context.scene.objects.active  
("Selected" + str(modifier_ob.name))  
mirror_ob.select = 0  
bpy.context.selected_objects  
data.objects[one.name].select  
print("please select exactly one object")
```

```
OPERATOR CLASSES  
types.Operator):  
X mirror to the selected  
select.mirror_mirror_x"  
mirror X"
```

```
context):  
object is not
```




Data Science Academy rodrigo.c.abreu@hotmail.com 5e207d48e32fc335fa60447d




**Data Science
Academy**

SVM's com Margens Rígidas X SVM's com Margens Flexíveis




As máquinas de vetores de suporte (chamadas SVMs) são um algoritmo de aprendizado supervisionado que pode ser usado para problemas de classificação e regressão como classificação de vetores de suporte (SVC) e regressão de vetores de suporte (SVR).



Os pontos mais próximos ao hiperplano são chamados de pontos do vetor de suporte e a distância dos vetores do hiperplano é chamada de margem.


A intuição básica a ser desenvolvida aqui é que quanto mais pontos SV adicionais, do hiperplano, maior a probabilidade de classificar corretamente os pontos em suas respectivas regiões ou classes. Os pontos SV são muito críticos na determinação do hiperplano porque se a posição dos vetores muda, a posição do hiperplano é alterada.

Tecnicamente, esse hiperplano também pode ser chamado de hiperplano de maximização de margem.



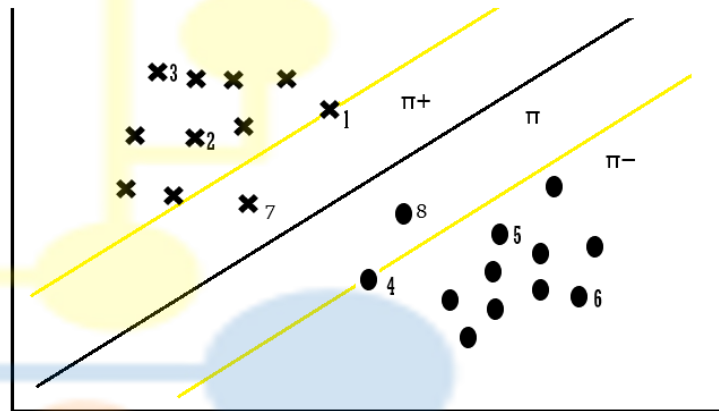


Margens Rígidas



x = points in
positive domain

● = points in
negative domain.



x = points in
positive domain

● = points in
negative domain.



Margens Rígidas

Se os pontos são linearmente separáveis, apenas o nosso hiperplano é capaz de distinguir entre eles e se algum erro for introduzido (outliers por exemplo), não será possível separá-los.

Esse tipo de SVM é chamado SVM de Margem Rígida (já que temos restrições muito rígidas para classificar corretamente cada ponto de dados).



Margens Flexíveis

Basicamente, consideramos que os dados são linearmente separáveis e isso pode não ser o caso no cenário da vida real.

Precisamos de uma atualização para que nossa função possa pular alguns valores discrepantes e poder classificar pontos quase linearmente separáveis. Por esse motivo, apresentamos uma nova variável Slack (ξ) chamada Xi.

Distância Mínima Entre os VS:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{\|\mathbf{w}\|}{2} + C \sum_{i=1}^N \xi^{(i)}, \\ \text{s. t.} \quad & y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \xi^{(i)}, \quad \forall i \in \{1, \dots, N\} \\ & \xi^{(i)} \geq 0, \quad \forall i \in \{1, \dots, N\} \end{aligned}$$



Margens Flexíveis

Se $\xi_i = 0$, os pontos podem ser considerados corretamente classificados.
Senão, se $\xi_i > 0$, pontos são classificados incorretamente.

Portanto, se $\xi_i > 0$ significa que X_i (variáveis) está na dimensão incorreta, podemos pensar em ξ_i como um termo de erro associado a X_i (variável).

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$




Resumindo

A margem rígida é aquela que separa claramente os pontos positivos e negativos.

A margem flexível também é chamada SVM linear “barulhenta”, pois inclui alguns pontos classificados incorretamente.



Parâmetro de Regularização C



Distância Mínima Entre os VS:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{\|\mathbf{w}\|}{2} + C \sum_{i=1}^N \xi^{(i)}, \\ \text{s. t.} \quad & y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \xi^{(i)}, \quad \forall i \in \{1, \dots, N\} \\ & \xi^{(i)} \geq 0, \quad \forall i \in \{1, \dots, N\} \end{aligned}$$

Maximizar a Distância Mínima (Otimização):

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha^{(i)} - \sum_{i=1}^N \sum_{j=1}^N \left(y^{(i)} \alpha^{(i)} \phi(\mathbf{x}^{(i)})^T \phi(\mathbf{x}^{(j)}) y^{(j)} \alpha^{(j)} \right) \\ \text{s. t.} \quad & 0 \leq \alpha^{(i)} \leq C, \end{aligned}$$



Parâmetro de Regularização C

O parâmetro de regularização C no Modelo SVM é responsável pelo treinamento do modelo com hiperplano de margem flexível ou rígida.

Quanto maior o valor de C menor a margem do hiperplano selecionada para o treinamento de um modelo.

Quanto menor o valor de C maior a margem do hiperplano escolhida para o treinamento de um modelo.

Para obter resultados de classificação mais precisos (menos amostras classificadas incorretamente), é necessário selecionar C com grande valor.



Continue Trilhando uma Excelente Jornada de Aprendizagem!

Muito Obrigado!