



**Data Science  
Academy**

[www.datascienceacademy.com.br](http://www.datascienceacademy.com.br)

**Machine Learning**

**Evolução dos Sistemas de Recomendação**



Ao longo dos anos, os sistemas de recomendação evoluíram, passaram de métodos mais básicos baseados em similaridades para sistemas de recomendações personalizadas, de recomendações baseadas em contexto, para recomendações em tempo real, de recomendações baseadas em heurísticas básicas, como cálculo de similaridade para abordagens baseadas em Machine Learning.

Nos estágios iniciais desses sistemas de recomendação, apenas as classificações dos usuários sobre os produtos foram utilizadas para gerar recomendações. Nessa época, os pesquisadores usavam apenas as informações de classificação disponíveis. Eles simplesmente aplicaram abordagens heurísticas como o cálculo de similaridade usando distâncias euclidianas, o coeficiente de Pearson, similaridade de cosseno e etc.... Essas abordagens foram bem recebidas e, surpreendentemente, elas funcionam muito bem até hoje.

Esta primeira geração de motores de recomendação é chamada de filtragem colaborativa ou sistemas de recomendação de métodos de vizinhança. Embora eles executem muito bem, estes sistemas vêm com seu próprio conjunto de limitações, tais como problemas de Cold Start (Início frio), quando não são capazes de recomendar produtos a novos usuários sem informações de classificação. Além disso, esses sistemas não conseguem lidar com cenários onde os dados são muito escassos, de modo que as classificações de usuários dos produtos são muito menores.

Para superar essas limitações, novas abordagens foram desenvolvidas. Por exemplo, a fim de lidar com problemas de conjuntos de dados muito esparsos, abordagens matemáticas, como Fatoração de Matriz e Singular Value Decompositions, têm sido utilizados. São técnicas matemáticas que ajudam a resolver problemas nos dados, aumentando a eficácia de sistemas de recomendação.

No início, os cálculos de similaridade foram usados em sistemas de recomendação baseados em conteúdo, mas com avanços em tecnologia e infraestrutura, métodos mais avançados, como modelos de aprendizado de máquina, substituíram os métodos heurísticos. Estes novos modelos baseados em Machine Learning melhoraram a precisão das recomendações. Embora os sistemas de recomendação baseados em conteúdo tenham resolvido muitas das deficiências da filtragem colaborativa, eles têm suas próprias deficiências inerentes, como não ser capaz de recomendar novos itens fora do escopo de preferência do usuário, o que a filtragem colaborativa poderia fazer.

Para resolver esse problema, os pesquisadores começaram a combinar diferentes modelos de recomendação para chegar a modelos híbridos, que são muito mais poderosos do que qualquer um dos modelos individuais. E esses modelos híbridos atualmente englobam não apenas os modelos tradicionais de sistemas de recomendação, como técnicas matemáticas e de Machine Learning, levando a sistemas totalmente personalizados a cada cliente.



Com implementações bem-sucedidas de mecanismos de recomendação personalizados, as pessoas começaram a estender a personalização a outras dimensões chamadas contextos, como a adição de localização, hora, grupo e assim por diante e alteraram o conjunto de recomendações com cada contexto. Com avanços em tecnologia como grandes ecossistemas de dados, ferramentas analíticas que executam em memória e em tempo real como o Apache Spark, a capacidade de manipulação de bancos de dados muito grandes tornou-se possível. Atualmente estamos nos movendo para sistemas ainda mais personalizados com o uso de inteligência artificial. No aspecto de tecnologia, as recomendações estão passando de abordagens de aprendizado de máquina para abordagens mais avançadas de aprendizagem profunda como redes neurais.

Agora, vamos implementar um sistema de recomendação completo!